

Sprawozdanie z Zadania: Systemy Rekomendacyjne

PDB26 - Introduction to Recommender Systems

Analiza algorytmu kNN oraz „Najwyżej oceniane” na zbiorze MovieLens 100k

Autor: Juliusz Radziszewski (s193504)

16.05.2026

1. Wprowadzenie i środowisko badawcze

Celem niniejszego sprawozdania jest analiza, strojenie hiperparametrów i porównanie dwóch algorytmów rekomendacyjnych. Pierwszym z nich jest algorytm k-Najbliższych Sąsiadów (kNN), a drugim autorski algorytm bazowy „Najwyżej oceniane” (Top Rated).

1.1. Zbiór danych (MovieLens 100k)

Do badań wykorzystano popularny, historyczny zbiór danych ~~m1-100k~~ udostępniony przez organizację GroupLens. Zbiór ten zawiera dokładnie 100 000 ocen (w skali od 1 do 5) wystawionych przez 943 użytkowników dla 1682 filmów. Każdy użytkownik w zbiorze ocenił co najmniej 20 filmów. Ze względu na swoją charakterystykę, macierz ocen jest w dużej mierze rzadka (sparse matrix), co stanowi typowe wyzwanie dla systemów Collaborative Filtering.

1.2. Metryki ewaluacyjne: MAE vs RMSE

Jakość algorytmów oceniano na podstawie dwóch najpopularniejszych metryk:

- **MAE (Mean Absolute Error)** - średni błąd bezwzględny. Oblicza uśrednioną różnicę między przewidywaną a rzeczywistą oceną. Jest intuicyjna w interpretacji (wynik MAE = 0.8 oznacza, że system myli się średnio o 0.8 gwiazdki).
- **RMSE (Root Mean Squared Error)** - pierwiastek błędu średniokwadratowego. Różnica polega na tym, że przed uśrednieniem błędy są podnoszone do kwadratu. Sprawia to, że RMSE **znacznie silniej karze duże pomyłki**. W systemach rekomendacyjnych jest to kluczowe – polecenie użytkownikowi filmu, którego bardzo nie lubi (duża różnica ocen), jest uznawane za gorsze niż delikatne pomyłki na kilku filmach letnich.

2. Strojenie hiperparametrów algorytmu kNN


W celu znalezienia optymalnej konfiguracji dla algorytmu `KNNBasic`, wykorzystano metodę przeszukiwania siatki (Grid Search). Przebadano następujące przestrzenie hiperparametrów:

- Liczba sąsiadów (**k**): 6 wariantów (10, 20, 30, 40, 50, 60)
- Miara podobieństwa: 3 warianty (msd, cosine, pearson)
- Podejście: 2 warianty (user_based oraz item_based).

Złożoność obliczeniowa poszukiwań:

Powyższa przestrzeń poszukiwań dała łącznie 36 unikalnych kombinacji parametrów ($6 \times 3 \times 2 = 36$). Aby zapewnić maksymalną rzetelność wyników i zminimalizować wpływ losowego podziału danych, zastosowano **3-krotną walidację krzyżową (3-fold Cross-Validation)**. Oznacza to, że dla każdej z 36 kombinacji, zbiór danych był dzielony na 3 równe części, a model był trenowany i ewaluowany trzykrotnie. W efekcie, środowisko testowe musiało zbudować potężne macierze podobieństwa i przetrenować modele predykcyjne aż **108 razy**.

Na Rysunku 1 zobrazowano, jak zmieniał się błąd RMSE w zależności od liczby sąsiadów dla wszystkich przebadanych miar i podejść. Widać wyraźnie, że najslabiej radzi sobie korelacja Pearsona, podczas gdy miara MSD osiąga najniższe wartości błędów.



Rysunek 1: Zależność błędu RMSE od parametru k (liczby sąsiadów) uwzględniająca różne miary podobieństwa oraz podejścia user/item-based.

W tabeli 1 przedstawiono pięć najlepszych wyników procesu optymalizacji uśrednionych z walidacji krzyżowej.

Miejsce	Liczba sąsiadów (k)	Miara podobieństwa	Podejście	Średnie RMSE
1	30	msd	User-based	0.9862
2	40	msd	Item-based	0.9863
3	20	msd	User-based	0.9864
4	50	msd	Item-based	0.9873
5	40	msd	User-based	0.9875

Tabela 1: Top 5 konfiguracji algorytmu kNN wyłonionych przez walidację krzyżową (Grid Search).

Decyzja: Do ostatecznego testu wybrano algorytm kNN z liczbą sąsiadów $k=30$, miarą podobieństwa **msd** oparty na podobieństwie użytkowników (**user-based**).

3. Implementacja algorytmu „Najwyżej oceniane”


Autorski algorytm wyznacza średnią ze wszystkich ocen dla każdego elementu w zbiorze treningowym. Podczas predykcji, model zachowuje się pasywnie, zwracając zapamiętaną średnią dla danego filmu bez jakiegokolwiek personalizacji. W przypadku pojawienia się w zbiorze testowym filmu nieznanego (problem **cold start**), algorytm zwraca asekuracyjnie globalną średnią wszystkich ocen ze zbioru treningowego.

4. Porównanie wyników i Wnioski

Ostateczny test przeprowadzono po uprzednim podziale danych na zbiór treningowy (75%) oraz testowy (25%). Zestawienie końcowych wyników dla obu algorytmów – na danych znanych (trening) i nieznanych (test) – zaprezentowano w Tabeli 2 oraz na Rysunku 2.

Algorytm	RMSE (Trening)	MAE (Trening)	RMSE (Test)	MAE (Test)
Zoptymalizowany kNN	0.7247	0.5605	0.9833	0.7755
Autorski Top Rated	0.9961	0.7958	1.0285	0.8195

Tabela 2: Zestawienie błędów RMSE i MAE dla badanych algorytmów na zbiorach treningowym i testowym.



Rysunek 2: Wizualizacja końcowych wartości błędu RMSE i MAE dla badanych algorytmów wyłącznie na nowym, testowym zbiorze danych.

Analiza i Wnioski:

- Przewaga Collaborative Filtering:** Algorytm kNN z wynikiem RMSE 0.9833 ewidentnie pokonuje algorytm bazowy (RMSE 1.0285). Różnica ta w dziedzinie systemów rekomendacyjnych jest statystycznie bardzo istotna i świadczy o udanym odnalezieniu ukrytych preferencji. Klasyczne podejście oparte na podobieństwie użytkowników (User-based) wygrało w ostatecznym rozrachunku z podejściem opartym na elementach.
- Rola kary za duże błędy:** Widać wyraźnie, że metryka RMSE zawsze przyjmuje wartości wyższe niż MAE dla obu modeli (np. kNN osiąga MAE na poziomie 0.7755 przy RMSE 0.9833). Wynika to z faktu matematycznego karania za duże pomyłki.
- Stabilność kNN vs Overfitting:** Analizując Tabelę 2, błąd kNN na zbiorze treningowym wynosił 0.7247 (RMSE). Gorszy wynik na zbiorze testowym (0.9833) wskazuje na wyraźną obecność przeuczenia modelu do danych znanych, co jest typowym zjawiskiem w podejściu **memory-based**. Z kolei algorytm „Najwyżej Oceniane” zachowuje się bliźniaczo na obu

zbiorach (RMSE ok. 1.00), ponieważ jako model statystyczny nie uczy się żadnych skomplikowanych wzorców, nie ryzykując tym samym zjawiska **overfittingu**.

4. **Złożoność pamięciowa a środowisko produkcyjne:** Warto zauważyć istotny inżynierski aspekt wyboru między podejściem **user-based** a **item-based**. Zbiór **ml-100k** posiada 943 użytkowników i 1682 filmy. Oznacza to, że macierz podobieństwa dla wygranego podejścia **user-based** ma rozmiar zaledwie 943×943 , podczas gdy dla konkurencyjnego **item-based** wynosiłaby 1682×1682 . Oznacza to, że zwycięski model okazał się nie tylko najdokładniejszy, ale również znacznie „lżejszy” i wymagałby mniej zasobów pamięci operacyjnej (RAM) na serwerach w ewentualnym środowisku produkcyjnym.